

Универзитет „Св. Кирил и Методиј“ во Скопје

Факултет за информатички науки и компјутерско инженерство

Напредни архитектури на граф невронски мрежи за пребарување и расудување над графови при одговарање на прашања над графови на знаење

ДИПЛОМСКА РАБОТА

Виктор Костадиноски · 226009


Ментор: проф. д-р Соња Гиевска

Септември 2026

Од прашање до одговор

Прашање

На кој континент се наоѓа Колосеумот?



Два посредни ентитети го поврзуваат прашањето со одговорот

Сродни пристапи и истражувачка празнина

GNN-RAG

GNN-пребарување → најкратки патеки → LLM

- GNN ги рангира ентитетите-кандидати.
- Најкратките патеки го формираат доказниот контекст.

G-Retriever


кодер на графови → PCST → LLM

- Кодерот на графови ги оценува јазлите.
- PCST избира компактен доказен подграф.

Истражувачка празнина

Недостига контролирана споредба на различни GNN-архитектури, стратегии за доказен подграф и јазични модели во една заедничка рамка.

Архитектура на системот



Резултатите од секоја фаза се следат одделно за да се утврди каде се губи потребната информација.

Истражувачки прашања

1

Архитектура за пребарување

Како изборот на GNN-архитектура влијае врз рангирањето и опфатеноста на точните одговори?

2

Доказен подграф

Како конструкцијата на доказниот подграф влијае врз компактната и зачувувањето на релевантните информации?

3

Јазичен модел

Како изборот на LLM влијае врз конечната точност и искористувањето на достапниот доказен контекст?

Податочно множество и експериментална поставеност

WebQuestionsSP

- Прашања на природен јазик поврзани со Freebase
- Локален граф за секое прашање
- Познати почетни ентитети и точни одговори

Заедничка евалуација

seeds: 42 · 1337 · 2026
праг: 0,7 · 10–15 кандидати

Поделба на податоците

2.848

тренирање

250

валидација


1.639

тестирање



1.889

обединети примероци за евалуација пред филтрирањето

Архитектури за пребарување



GraphSAGE и Advance GraphSAGE



Клучна разлика

$$\alpha(q, r) = \cos(q, r)$$


$$\alpha(q, r) = \text{sigmoid}(\text{MLP}[\tilde{q} \parallel \tilde{r} \parallel \tilde{q} \odot \tilde{r}])$$

- Обратни рабови и резидуални врски
- Нормализација и оценка условена од прашањето

Од фиксно семантичко пондерирање кон научен gate за конкретното прашање.


R-GCN и HGT

R-GCN



Трансформација според типот на релацијата

HGT



Релациски зависен attention

R-GCN

$$h_v^{(l+1)} = \sigma(W_0^{(l)} h_v^{(l)} + \sum_r \sum_u 1/c_{v,r} \cdot W_r^{(l)} h_u^{(l)})$$


- Различна трансформација за секој тип релација

HGT

$$\alpha_{r,j_{uv}} = \text{softmax}(e_{r,j_{uv}})$$

- Релациски зависен attention за соседите

И двете архитектури ја задржуваат релациската структура, но ја моделираат на различен начин.



Инструкциите се менуваат според информацијата откриена во графот


Приспособливо расудување

- Повеќе инструкции се извлекуваат од прашањето.
- Инструкциите го насочуваат преносот на пораки.
- Собраната информација ги ревидира инструкциите.

$$m^{k,t_{u,r}} = p_{t_u} \text{ReLU}(W_{t,r}^t \odot i^k)$$

ReaRev го менува толкувањето на прашањето според информацијата откриена во графот.

NBFNet



Патеките и релациите се условени од прашањето

Научена Bellman–Ford постапка

$$h_v^{(0)} = q \text{ ако } v \in S; 0 \text{ во спротивно}$$

$$m_{u,r,v}^{(l)} = h_u^{(l)} \odot w_r^{(l)}(q)$$

- Патеките и релациите се условени од прашањето.
- Поддржани се повеќе почетни ентитети.

Репрезентацијата на кандидатот опишува како тој се достигнува преку патеки релевантни за прашањето.

Метрики за пребарување

Рангирање

- Hits@1 / Hits@10 — барем еден точен одговор во првите 1 или 10 позиции
- nDCG@10 — позицијата и бројот на точни одговори во првите 10

Покриеност на точните одговори

$$\text{RetrievalGoldCoverage} = (1/|Q|) \sum_q |G_q \cap R_q| / |G_q|$$

$$\text{RetrievalFullGoldCoverage} = (1/|Q|) \sum_q \mathbb{I}(G_q \subseteq R_q)$$

Пример

2 / 3


пронајдени точни одговори

0

целосна покриеност

G_q — точни одговори · R_q — пребарани кандидати

Резултати од пребарувањето



NBFNet

0,692

Hits@1

0,921

Hits@10

0,796


nDCG@10

средна вредност од 3 извршувања

Условувањето со прашањето и експлицитното моделирање на релациските патеки даваат најдобри резултати.
Advance GraphSAGE е силен едноставен компромис.

Конструкција на доказниот подграф


Унија на најкратки патеки



Се задржува патека до секој достиген кандидат

повеќе тројки

PCST



Наградите на јазлите се споредуваат со трошоците на рабовите

компактен подграф

PCST: награда на јазлите наспроти трошок на рабовите

$$T^* = \arg \max_T [\sum_{v \in V_T} p(v) - \sum_{e \in E_T} c(e)]$$

$$c_{\text{const}}(e) = \lambda$$

$$c_{\text{sem}}(e) = \max(\epsilon, \lambda[1 - \cos(q, re)])$$

Најкратките патеки гарантираат поврзаност до секој кандидат; PCST може да отфрли кандидат кога поврзувањето е прескапо.

Метрики за доказниот контекст

Компактност

AverageTriples

просечен број тројки

ContextCandidateCoverage

удел на задржани кандидати

CandidateReduction

процент отфрлени кандидати

Зачувана информација

$$\text{ContextGoldCoverage} = (1/|Q|) \sum_q |G_q \cap C_q| / |G_q|$$


$$\text{ContextFullGoldCoverage} = (1/|Q|) \sum_q \mathbb{I}(G_q \subseteq C_q)$$

C_q — ентитети присутни во тројките од доказниот контекст

Компактноста се оценува заедно со информацијата што останува достапна за јазичниот модел.

Компактност и зачувување на точните одговори

--- Унија на најкратки патеки PCST, константна цена PCST, семантичка цена



≈ 85%
помал доказан контекст со PCST

Просечен број тројки

94,47

најкратки патеки

13,50–14,45

PCST

Покриеноста се намалува минимално:

ContextGoldCoverage 0,888 → ≈0,881
ContextFullGoldCoverage 0,838 → ≈0,830

Стратегијата на трошок има поголемо
влијание од малите промени на λ.

Метрики за конечниот одговор

Квалитет на одговорот

- Hit — вратен е барем еден точен одговор
- ExactMatch — целосно совпаѓање на множествата
- Precision · Recall · F1 — квалитет на генерираното множество

Искористување на контекстот

FullContextCompleteAnswer

Контекстот ги содржи сите точни одговори и моделот ги враќа сите.


FullContextLLMOmission

Контекстот е целосен, но моделот испушта најмалку еден точен одговор.

$$\text{LLMOmissionGivenFullContext} = \#\{q: Gq \subseteq Cq \wedge Gq \not\subseteq Pq\} / \#\{q: Gq \subseteq Cq\}$$

Метриката го изолира пропустот на јазичниот модел од загубата во претходните фази.

Квалитет и потрошувачка на токени



Унија на најкратки патеки

0,802 / 0,804 0,627 / 0,613 3,42 / 3,07 M


Hit · DeepSeek / GPT F1 · DeepSeek / GPT токени · DeepSeek / GPT

Семантички PCST, $\lambda=1$

0,689 / 0,728 0,492 / 0,477 0,69 / 0,66 M

Hit · DeepSeek / GPT F1 · DeepSeek / GPT токени · 78–80% помалку

Каде се губи информацијата?



Заклучоци

1

NBFNet е најуспешен и најстабилен пребарувач

Hits@10 = $0,921 \pm 0,005$ · nDCG@10 = $0,796 \pm 0,007$

2

Најкратките патеки го даваат највисокиот конечен квалитет

Семантичкиот PCST создава $\approx 85\%$ помал контекст и е подобар кога компактоста е приоритет.

3

Изборот на LLM го менува балансот меѓу Hit и F1

Главното тесно грло е искористувањето на достапниот релациски контекст.

Идни подобрувања

Хибриден доказен подграф

Компактност на PCST со гарантирано зачувување на целосни и разбирливи патеки до најважните кандидати.

Заедничка оптимизација

Пребарувачот и конструкцијата на подграфот заеднички да учат кои патеки се најкорисни за јазичниот модел.

Поширока евалуација

Дополнителни податочни множества, подолги патеки на расудување, повеќе извршувања и други јазични модели.

Целта е доказниот контекст истовремено да биде компактен и доволно јасен за јазичниот модел.

Ви благодарам

Прашања?

Виктор Костадиноски · 226009

github.com/ltonkdong/graphragx