



Универзитет „Св. Кирил и Методиј“ во Скопје
**ФАКУЛТЕТ ЗА ИНФОРМАТИЧКИ НАУКИ И
КОМПЈУТЕРСКО ИНЖЕНЕРСТВО**



**НАПРЕДНИ АРХИТЕКТУРИ НА ГРАФ
НЕВРОНСКИ МРЕЖИ ЗА ПРЕБАРУВАЊЕ И
РАСУДУВАЊЕ НАД ГРАФОВИ ПРИ
ОДГОВАРАЊЕ НА ПРАШАЊА НАД
ГРАФОВИ НА ЗНАЕЊЕ**

————— ДИПЛОМСКА РАБОТА —————

Ментор

проф. д-р Соња Гиевска

Кандидат

Виктор Костадиноски
226009

септември 2026

Содржина

Апстракт	4
1 Вовед	5
2 Теоретска основа и сродни истражувања	6
3 Методологија и архитектура на системот	8
3.1 Архитектура на системот	9
3.2 Напредни архитектури на граф невронски мрежи	13
3.3 Конструкција на доказен подграф	17
3.4 Генерирање на конечниот одговор	20
4 Експериментална поставеност	21
4.1 Метрики за пребарување	22
4.2 Метрики за доказниот контекст	24
4.3 Метрики за конечниот одговор	25
4.4 Прв експеримент: споредба на архитектурите за пребарување . . .	27
4.5 Втор експеримент: споредба на постапките за конструкција на доказниот контекст	27
4.6 Трет експеримент: оценување на целосниот систем	28
5 Резултати и дискусија	28
6 Заклучок	37
7 Идни подобрувања	39

Листа на табели

1	Главни карактеристики на архитектурите за пребарување одговори.	18
2	Заедничка конфигурација за тренирање и пребарување.	23
3	Резултати од пребарувањето за различните архитектури. Вредностите се прикажани како средна вредност $\pm$ стандардна девијација од три извршувања. Најдобриот резултат за секоја метрика е означен со задебелен текст.	29
4	Споредба на постапките за конструкција на доказниот подграф. Вредностите се прикажани како средна вредност $\pm$ стандардна девијација од три извршувања.	31
5	Квалитет на конечните одговори и вкупен број потрошени токени. Највисоката вредност за секоја метрика за квалитет и најмалиот број токени се означени со задебелен текст.	33

Листа на слики

1	Преглед на целосниот тек: од подготовка на прашањето и локалниот граф, преку пребарување ентитети-кандидати и конструкција на доказен подграф, до конечен одговор од јазичниот модел.	10
2	Последователно стеснување на информациите: од јазли во локалниот граф, преку пребарани ентитети-кандидати и ентитети присутни во доказниот подграф, до одговори вратени од јазичниот модел.	12
3	Споредба на главните метрики за пребарување. Столбовите ја прикажуваат средната вредност, а ознаките за отстапување ја прикажуваат стандардната девијација од трите извршувања. . . .	29
4	Влијание на параметарот λ врз големината на доказниот подграф, намалувањето на кандидатите и покриеноста на точните одговори. Испрекинатата линија го означува резултатот на унијата на најкратки патеки.	32
5	Квалитет на конечниот одговор и број потрошени токени за различните доказни подграфови. Во приказот на токени, главниот дел од секој столб го претставува влезниот контекст, а горниот шрафиран дел ги претставува излезните токени.	34

6	Исходи од искористувањето на точните одговори присутни во до- казниот контекст.	35
---	--	----

Апстракт

За да се одговори на прашање над граф на знаење, потребно е од големиот број ентитети и релации да се издвојат информациите релевантни за добивање на точниот одговор. Во оваа дипломска работа се истражува систем што ги интегрира пребарувањето на кандидати за одговор со граф невронски мрежи, конструкцијата на доказен подграф и генерирањето конечни одговори со големи јазични модели. Целта е да се утврди како изборот на архитектура за пребарување и начинот на формирање на доказниот контекст влијаат врз точноста на системот.

Експерименталната евалуација е спроведена врз WebQSP податочното множество, при што се споредуваат шест архитектури: GraphSAGE, Advance GraphSAGE, R-GCN, HGT, ReaRev и NBFNet. За конструкција на доказниот подграф се разгледуваат два пристапа: унија на најкратки патеки и дрво на Штајнер со награди (PCST), при што за PCST се анализираат варијанти со константна и семантички определена цена на ребрата. Конечните одговори се генерираат со моделите DeepSeek-V4-Flash и GPT-5.6 Luna, а перформансите на секоја фаза од системот се оценуваат одделно.

Резултатите покажуваат дека NBFNet постигнува најдобри перформанси во фазата на пребарување, со Hits@10 од 0.921 ± 0.005 . Комбинацијата на NBFNet со унијата на најкратки патеки постигнува и највисока стапка на погодок кај конечните одговори, од приближно 0.80 за двата јазични модели. Употребата на PCST го намалува просечниот број тројки за околу 85%, а потрошувачката на токени за приближно 78–80%, но притоа се забележува намалување на квалитетот на конечните одговори. Семантичката варијанта на PCST, пак, обезбедува поповолен компромис меѓу компактната на доказниот контекст и точноста на одговорите. Анализата дополнително покажува дека високата покриеност на точните ентитети во доказниот контекст не е доволна за нивно успешно вклучување во конечниот одговор. Овој резултат ја нагласува важноста не само на присуството на релевантните ентитети, туку и на соодветните релации меѓу нив, како и на способноста на јазичниот модел ефективно да ги искористи информациите содржани во доказниот подграф.

Целосниот изворен код, заедно со резултатите од експериментите, е достапен на <https://github.com/Itonkdong/graphragx>.

1 Вовед

Мотивација. Графовите на знаење ги претставуваат фактите преку ентитети и релации меѓу нив, со што овозможуваат експлицитно моделирање на врските во податоците. Ваквата структура е особено погодна за одговарање на прашања кај кои точниот одговор не зависи само од еден изолиран факт, туку од поврзувањето на повеќе факти низ графот. Сепак, подграфот специфичен за едно прашање може да содржи голем број ентитети и релации што не се релевантни за одговорот. Поради тоа, еден од главните предизвици е да се пронајде малото множество јазли што најверојатно ги содржи точните одговори, притоа земајќи ги предвид и семантиката на прашањето и структурата на графот.

Големите јазични модели (Large Language Models, LLMs) имаат изразена способност за разбирање на природниот јазик и генерирање текст, но знаењето содржано во нивните параметри не е секогаш доволно за прецизно одговарање на прашања што зависат од конкретен надворешен извор и доменско знаење. Генерирањето збогатено со пребарување (Retrieval-Augmented Generation, RAG) го ублажува ова ограничување со пронаоѓање релевантни информации пред генерирањето на одговорот и нивно внесување како дополнителен контекст за јазичниот модел [1]. Кога надворешниот извор, пак, е граф на знаење, пребарувањето не само што треба да ги земе предвид текстуалната и семантичката сличност, туку потребно е да се опфатат и релациите, соседството и патеките меѓу ентитетите.

Граф невронските мрежи (Graph Neural Networks, GNN) претставуваат природен избор за пребарување и расудување над графови на знаење. Различните архитектури, сепак, се разликуваат во начинот на кој ги обработуваат соседите, типовите на релации, прашањето и можните патеки до одговорот. Оттука произлегува потребата систематски да се испита како различни архитектури на граф невронски мрежи влијаат врз квалитетот на пребарувањето во еднакви експериментални услови.

Покрај изборот на одговори-кандидати, значајна улога има и конструкцијата на доказниот подграф што му се доставува на јазичниот модел. Премногу обемен контекст може да вклучи нерелевантни информации и да го отежни генерирањето на точен одговор, додека премногу ограничен контекст може да изостави ентитети и релации неопходни за негово генерирање. За решавање на овој проблем се применуваат повеќе пристапи, меѓу кои унијата на најкратките патеки и дрвото на Штајнер со награди (Prize-Collecting Steiner Tree, PCST), пристап кој овозможува конструкција на компактен и поврзан доказен подграф.

Проблем и цел на трудот. Во рамките на оваа дипломска работа е опфатен систем за одговарање на прашања над графови на знаење составен од три последователни фази: пребарување на ентитети-кандидати, конструкција на доказен

подграф и генерирање конечен одговор. Основната цел е да се утврди како изборите во секоја од овие фази влијаат врз конечниот резултат. За таа цел се споредуваат шест архитектури за пребарување, две основни стратегии за конструкција на доказниот подграф и два големи јазични модели. Дополнително, резултатите се следат одделно во секоја фаза, со што може да се утврди дали информацијата потребна за точен одговор е изгубена при пребарувањето, при конструкцијата на контекстот или при неговото искористување од јазичниот модел.

Истражувачки прашања. Во трудот се разгледуваат следните истражувачки прашања:

1. Како изборот на архитектура на граф невронска мрежа влијае врз рангирањето и опфатеноста на точните одговори?
2. Како стратегијата за конструкција на доказниот подграф влијае врз неговата компактност и врз зачувувањето на релевантните информации?
3. Како изборот на голем јазичен модел влијае врз конечната точност и искористувањето на достапниот доказен контекст?

Организација на дипломска работата. Во продолжение во Поглавје 2 најпрво се прикажани потребната теоретска основа и сродните истражувања. Во Поглавје 3 се опишани методологијата, архитектурите за пребарување и стратегиите за конструкција на доказниот подграф. Експерименталната поставеност е претставена во Поглавје 4, а добиените резултати и нивната дискусија во Поглавје 5. На крај, заклучоците се изложени во Поглавје 6, додека можните насоки за понатамошни подобрувања се наведени во Поглавје 7.

2 Теоретска основа и сродни истражувања

Графови на знаење и одговарање на прашања. Графот на знаење претставува структурирана збирка од ентитети и семантички врски меѓу нив. Знаењето најчесто се изразува преку тројки од обликот (h, r, t) , каде што h е почетен ентитет, r е релација, а t е краен ентитет [2]. При одговарање на прашања над графови на знаење, прашањето поставено на природен јазик се поврзува најпрво со еден или повеќе почетни ентитети, по што низ графот се бараат ентитетите што претставуваат можни одговори. Кај посложените прашања, потребниот факт не е достапен преку една директна релација, туку преку патека составена од повеќе последователни релации.

Граф невронски мрежи. Граф невронските мрежи учат векторски репрезентации од латентни фактори (embeddings) на јазлите преку размена и агрегација

на информации од нивните соседства. На пример, GraphSAGE (Graph Sample and Aggregate), предложен од Hamilton et al. [3], формира векторска репрезентација на јазолот со повторлива агрегација на карактеристиките од неговите соседи. Со повеќе вакви последователни слоеви, информациите можат да се пренесуваат низ повеќе нивоа во графот, што овозможува формирање на репрезентации на ентитетите според нивната структурна и семантичка поврзаност.

Сродни архитектури. Различните архитектури на граф невронски мрежи воведуваат различни индуктивни претпоставки за начинот на којшто треба да се пренесуваат информациите. GraphSAGE ги третира соседствата преку заедничка агрегациска постапка, додека R-GCN (Relational Graph Convolutional Network) користи трансформации зависни од типот на релацијата и со тоа непосредно ја моделира повеќерелацииската природа на графовите на знаење [4]. Hu et al. [5] со HGT (Heterogeneous Graph Transformer) го проширува овој пристап со multi-head attention механизам којшто зависи од типот на јазлите и релациите и овозможува моделот да ја процени важноста на поединечните пораки.

Наспроти архитектурите што првенствено создаваат векторски репрезентации на јазлите, ReaRev е осмислен непосредно за одговарање на прашања над графови на знаење. Моделот извлекува инструкции од прашањето, ги извршува над графот и повторливо ги ревидира според информациите добиени во текот на расудувањето [6]. NBFNet, пак, го формулира расудувањето над графови како научена варијанта на алгоритмот Bellman–Ford и ги претставува врските меѓу ентитетите преку збир од релевантни патеки [7].

Конструкција на доказан подграф. Рангираните ентитети-кандидати не се доволни сами по себе за јазичниот модел, бидејќи без релациите и посредните ентитети не е јасно зошто тие се можни одговори. Еден пристап е да се земе унијата од најкратките патеки меѓу ентитетите од прашањето и избраните кандидати. Таквиот пристап ги задржува сите кандидати за кои постои патека, но може да внесе непотребни или преклопувачки факти. Алтернативно, проблемот може да се постави како дрво на Штајнер со награди (Prize-Collecting Steiner Tree, PCST), при што јазли носат награда, а вклучувањето рабови има цена [8]. Со тоа се бара компактен поврзан подграф што воспоставува рамнотежа меѓу опфатот на релевантните ентитети и големината на доказниот контекст.

Позиционирање на трудот. GNN-RAG на Mavromatis and Karypis [9] воспоставува иницијална рамка во која граф невронска мрежа се користи за пребарување ентитети-кандидати од густ подграф, а најкратките патеки од ентитетите во прашањето до пронајдените кандидати се користат како контекст за голем јазичен модел. Овој пристап покажува дека граф невронските мрежи може да дејствуваат како структурен пребарувач, додека конечното расудување го извршува јазичниот модел.

G-Retriever, предложен од He et al. [10], го разгледува проблемот над поширо-

ка класа текстуални графови и го формулира изборот на доказниот подграф како проблем на дрво на Штајнер со награди. На тој начин се ограничува количината на информации од графот доставена до јазичниот модел. GNN-RAG и G-Retriever, според тоа, ги потврдуваат двете основни идеи врз кои се надоврзува овој труд: употреба на граф невронска мрежа за пребарување и претворање на пронајдените информации во структуриран доказен подграф.

Сепак, овие истражувања не даваат контролирана споредба на повеќе суштински различни архитектури на граф невронски мрежи во единствена рамка, ниту, пак, заеднички го испитуваат влијанието на архитектурата за пребарување, постапката за конструкција на доказниот подграф и изборот на јазичниот модел врз крајните резултати.

3 Методологија и архитектура на системот

Формулација на проблемот. Проблемот ќе го разгледуваме како проблем на пребарување одговори во граф на знаење, проследен со конструкција на доказен подграф и генерирање конечен одговор. Секој примерок i од податочното множество е претставен со четворката

$$\mathcal{X}_i = (q_i, G_i, S_i, A_i), \quad (1)$$

каде што q_i е прашањето на природен јазик, $G_i = (V_i, E_i)$, подоцна именуван како локален граф, е графот поврзан со прашањето q_i , $S_i \subseteq V_i$ е множеството ентитети препознаени во прашањето (почетни ентитети), а $A_i \subseteq V_i$ е множеството точни одговори. Графот е насочен и повеќерелациски, па секој раб се претставува како тројка (u, r, v) , каде што u и v се ентитети, а r е семантичката релација меѓу нив.

Првата цел е да се научи функција за пребарување

$$f_{\theta}(q_i, G_i, S_i) \longrightarrow \{z_{iv} \mid v \in V_i\}, \quad (2)$$

која на секој јазол v му доделува вредност z_{iv} што ја изразува неговата веројатност тој јазол да претставува можен одговор на прашањето. Параметрите θ зависат од избраната архитектура на граф невронска мрежа. Бидејќи архитектурите користат различни излезни функции и функции на загуба, вредностите z_{iv} се претвораат во споредливи веројатности p_{iv} преку постапка соодветна на конкретната архитектура.

Од рангираните јазли се избира ограничено множество ентитети-кандидати C_i . Изборот се врши според праг на веројатност (threshold), дополнет со највисоко

рангираните јазли кога бројот на јазли над прагот е премал. На тој начин се избегнува создавање празно или премногу мало множество кандидати кај модели со послабо калибрирани веројатности. Вкупниот број кандидати е, исто така, ограничен со цел контекстот да остане компактен.

Следната цел е од графот G_i , почетните ентитети S_i и ентитетите-кандидати C_i да се изгради доказен подграф

$$H_i = \mathcal{B}(G_i, S_i, C_i), \quad (3)$$

каде што $\mathcal{B}$ е избраниот алгоритам за конструкција. Подграфот треба да ги поврзе релевантните ентитети со почетните ентитети и истовремено да ја ограничи количината на нерелевантни факти.

Конечниот одговор се добива со јазичен модел $\mathcal{L}$:

$$\hat{A}_i = \mathcal{L}(q_i, \text{verbalize}(H_i)), \quad (4)$$


каде што $\text{verbalize}(H_i)$ ги претвора избраните тројки во текстуален контекст. Бидејќи едно прашање може да има повеќе точни одговори, A_i и $\hat{A}_i$ се третираат како множества, а не како единечни вредности или подредени низи.

Оваа формулација на проблемот овозможува успешноста да се разгледува во три одделни фази: дали точните одговори се избрани од моделот, дали се задржани во доказниот подграф и дали јазичниот модел ги вклучил во конечниот одговор. Со тоа конечната грешка не се припишува автоматски на целиот систем, туку може да се поврзе со фазата во која е изгубена потребната информација.

3.1 Архитектура на системот

Предложениот систем е организиран во четири главни функционални целини: подготовка на графовите, пребарување ентитети-кандидати, конструкција на доказен подграф и генерирање конечен одговор. Ваквата поделба е прикажана на Слика 1.

Подготовка на графот. За секое прашање се користи неговиот локален граф. Овој граф го определува просторот на ентитети што можат да бидат рангирани како одговори. За секој јазол се создава локален идентификатор, а секој факт се претвора во насочен раб со означен тип на релација. Почетните ентитети го определуваат местото од кое треба да започне расудувањето над графот, додека точните одговори се користат за надгледувано тренирање и за пресметување на функцијат на загуба и метриците.



Слика 1: Преглед на целосниот тек: од подготовка на прашањето и локалниот граф, преку пребарување ентитети-кандидати и конструкција на доказен подграф, до конечен одговор од јазичниот модел.

Во зависност од архитектурата, моделот може да користи различни влезни информации. Сепак, сите архитектури добиваат ист локален граф и треба да произведат вредност за веројатноста за кандидат за секој негов јазол.

Тренирање на пребарувачот. За секој примерок јазлите што припаѓаат на множеството A_i се означуваат како точни одговори. Графот потоа се обработува низ избраната архитектура, а добиените излезни вредности се споредуваат со референтните вредности. Начинот на нормализација и функцијата на загуба се приспособени на природата на архитектурата: архитектурите што ги разгледуваат јазлите како независни кандидати користат бинарно оценување, додека ReaRev учи распределба на веројатност низ јазлите во секој локален граф. И покрај оваа разлика, сите модели се тренираат за иста крајна задача: повисоко рангирање на јазлите што претставуваат точни одговори.

Тренирањето резултира со модел што може да се примени независно од подоцнежните фази. Ова е важно за експерименталната поставеност, бидејќи иста истренирана архитектура може да се оцени со повеќе начини на конструкција на доказниот подграф без повторно тренирање. Слично, ист доказен контекст може да се достави до различни јазични модели. На тој начин промената во една компонента не ги менува резултатите од претходните компоненти.

Пребарување ентитети-кандидати. При евалуација, тренираниот модел создава вредност за веројатност за секој јазол од локалниот граф. Јазлите се подредуваат според веројатноста, по што се применува заедничка постапка за избор на кандидати. Нека

$$T_i(\tau) = \{v \in V_i \mid p_{iv} \geq \tau\} \quad (5)$$

е множеството јазли чија веројатност е најмалку τ , а $\text{TopK}(p_i, k)$ се k -те највисоко рангирани јазли. Почетното множество кандидати се определува како

$$C'_i = T_i(\tau) \cup \text{TopK}(p_i, k), \quad (6)$$

при што дополнувањето со TopK се применува само кога бројот на јазли над прагот е помал од зададениот минимум. По повторното подредување, се задржуваат најмногу L кандидати:

$$C_i = \text{TopL}(C'_i, L). \quad (7)$$

Оваа постапка има две намени. Прагот ги задржува сите јазли за кои моделот изразува доволна сигурност, додека долната граница k обезбедува основно множество кандидати дури и кога излезните веројатности се ниски. Горната граница L го ограничува количеството информации што продолжува кон конструкцијата на доказниот подграф. Конкретните вредности на τ , k и L се зададени во Потпоглавје 4.1 и се исти за сите архитектури.

Резултатот од оваа фаза не е само конечниот список кандидати. Се зачувува нивниот редослед, веројатноста, излезната вредност на моделот и информацијата дали кандидатот е точен одговор. Последното поле се користи исклучиво за евалуација и нема влијание врз изборот на доказниот подграф или врз повикот до јазичниот модел.

Конструкција на доказниот подграф. Рангираниот список го определува множеството потенцијални одговори, но не ги содржи фактите што ги поврзуваат тие одговори со прашањето. Поради тоа, следната фаза повторно го користи локалниот граф и за секој кандидат бара релевантна поврзувачка структура.

Кај првиот пристап се наоѓаат најкратките патеки од секој почетен ентитет до секој ентитет-кандидат. Кога постојат повеќе патеки со иста минимална должина, сите факти од сите минимални патеки се задржани во обединетиот доказен подграф. Пребарувањето на поврзаноста се врши независно од насоката на рабовите, но во конечниот контекст секоја тројка се прикажува во нејзината оригинална насока и со оригиналната релација.


Вториот пристап го формулира изборот како вкоренет (rooted) проблем на дрво на Штајнер со награди. Ентитетите-кандидати добиваат награди според нивниот ранг, а рабовите добиваат трошок. Алгоритмот може да отфрли кандидат кога неговата награда не го оправдува трошокот потребен за негово поврзување. Во рамки на системот, разгледани се две варијанти: константен трошок за сите рабови и семантички трошок зависен од сличноста меѓу прашањето и текстот на релацијата. Деталната формулација на двата пристапи е дадена во Потпоглавје 3.3.

Избраните тројки се дедуплицираат и се претвораат во компактен текстуален контекст. На крај, јазичниот модел ги добива прашањето во природен јазик и конечниот список тројки што го сочинуваат доказниот подграф, односно контекстот.

Генерирање на одговорот. Јазичниот модел добива инструкција да одговори исклучиво врз основа на приложениот контекст. Неговата улога е да ги поврзе фактите од доказниот подграф со семантиката на прашањето и да ги врати релевантните ентитети како конечен одговор. Во експериментите не се бара дополнително текстуално образложение, со што излезот останува насочен кон проценка на точноста на одговорот.

Системот поддржува прашања со повеќе точни одговори. Поради тоа, генерираниот текст се нормализира во множество одговори, а споредбата со референтното множество не зависи од нивниот редослед. Неуспешен повик или невалиден одговор од јазичниот модел се смета за неточен одговор.

Одделно следење на фазите. Една иста конечна грешка може да има повеќе причини. Точниот ентитет може да не постои во локалниот граф, пребарувачот може да не го избере, алгоритмот за доказниот подграф може да го исклучи или јазичниот модел може да не го врати иако бил присутен во контекстот. Поради тоа, системот ги зачувува резултатите од секоја фаза одделно, како што е прикажано на Слика 2.



Слика 2: Последователно стеснување на информациите: од јазли во локалниот граф, преку пребарани ентитети-кандидати и ентитети присутни во доказниот подграф, до одговори вратени од јазичниот модел.

Оваа поделба е основа за подоцнежната анализа на загубата на информации. Покрај класичните метрики за рангирање и точност, се мери колкав дел од точните одговори се зачувани при преминот од пребарувањето кон доказниот контекст и колкав дел од достапните точни одговори се искористени од јазичниот модел. На тој начин може да направи разлика помеѓу слаб пребарувач, несоодветно конструиран контекст или пропуст во конечното генерирање.

3.2 Напредни архитектури на граф невронски мрежи

Во рамките на системот се разгледуваат шест архитектури на граф невронски мрежи. Тие се избрани така што претставуваат постепен премин од општа агрегација на соседството кон релативски attention, приспособливо расудување водено од прашањето и расудување засновано врз патеки.

GraphSAGE. GraphSAGE е основната архитектура во споредбата. Оригиналниот модел на Hamilton et al. [3] создава векторска репрезентација на еден јазол преку агрегација на информациите од неговото локално соседство. Во применетата варијанта, почетната репрезентација на секој ентитет добиена со екстерен енкодер се проектира во заедничка скриена димензија, а пораките од соседните јазли се пондерираат според косинусната сличност помеѓу прашањето и релацијата на соодветниот раб.

Односно, за јазолот v , пораката во слојот l може поедноставено да се запише како

$$\mathbf{m}_v^{(l)} = \sum_{(u,r,v) \in E} \alpha(q, r) \mathbf{W}_m^{(l)} \mathbf{h}_u^{(l)}, \quad (8)$$

каде што $\alpha(q, r)$ е семантичката сличност меѓу прашањето и релацијата. Новата репрезентација се добива со спојување на претходната состојба на јазолот со агрегираната порака:

$$\mathbf{h}_v^{(l+1)} = \sigma(\mathbf{W}_u^{(l)} [\mathbf{h}_v^{(l)} \parallel \mathbf{m}_v^{(l)}]). \quad (9)$$

По последниот слој, повеќеслоен перцептрон создава логит за секој јазол. Оваа архитектура претставува едноставна почетна точка: прашањето влијае врз тежината на рабовите, но самиот механизам за пренос на пораки не учи посебна трансформација за секој тип релација.

Advance GraphSAGE. Advance GraphSAGE е проширување на претходната архитектура создадено во рамките на оваа дипломска работа. Наместо тежината на работ да се определува само преку косинусна сличност, таа се учи со повеќеслоен перцептрон што ги прима проектираното прашање, проектираната релација и нивната елементна интеракција:

$$\alpha(q, r) = \text{sigmoid}(\text{MLP} [\tilde{\mathbf{q}} \parallel \tilde{\mathbf{r}} \parallel \tilde{\mathbf{q}} \odot \tilde{\mathbf{r}}]). \quad (10)$$

Архитектурата дополнително користи обратни рабови, резидуални врски и нормализација по слоеви. Конечниот класификатор е непосредно условен од прашањето и го оценува секој јазол врз основа на

$$[\mathbf{h}_v \parallel \tilde{\mathbf{q}} \parallel \mathbf{h}_v \odot \tilde{\mathbf{q}}]. \quad (11)$$

Со овие дополнувања моделот може да научи кои релации се корисни за конкретното прашање и дали конечната репрезентација на јазолот е семантички усогласена со него. Сепак, основата останува иста како кај GraphSAGE: соседните јазли испраќаат пораки преку заеднички трансформации.

R-GCN. Релациската граф конволуциска мрежа, R-GCN, е создадена за графови со различни семантички типопови на рабовите [4]. Наместо една заедничка трансформација за сите рабови, R-GCN користи трансформација зависна од релацијата:

$$\mathbf{h}_v^{(l+1)} = \sigma \left(\mathbf{W}_0^{(l)} \mathbf{h}_v^{(l)} + \sum_{r \in \mathcal{R}} \sum_{u \in \mathcal{N}_v^r} \frac{1}{c_{v,r}} \mathbf{W}_r^{(l)} \mathbf{h}_u^{(l)} + \mathbf{b}^{(l)} \right). \quad (12)$$

Со $\mathcal{N}_v^r$ се означува множеството соседи поврзани со јазолот v преку релацијата r , додека $c_{v,r}$ го нормализира бројот на такви пораки. Матрицата $\mathbf{W}_0$ ја задржува информацијата за самиот јазол.

Бидејќи бројот на различни релации е голем, независна целосна матрица за секоја релација би создала голем број параметри. Затоа се користи декомпозиција преку помал број базни матрици:

$$\mathbf{W}_r^{(l)} = \sum_{b=1}^B a_{rb}^{(l)} \mathbf{V}_b^{(l)}. \quad (13)$$

Коефициентите a_{rb} определуваат како заедничките бази се комбинираат за секоја релација. Оригиналните и обратните рабови добиваат различни релациски идентификатори, со што насоката на фактот останува зачувана. За разлика од двете GraphSAGE-варијанти, R-GCN не го користи прашањето при преносот на пораки; тој учи релациски зависни репрезентации на јазлите, кои потоа се оценуваат со заедничкиот класификатор.

HGT. Heterogeneous Graph Transformer, односно HGT, воведува multi-head attention од релациите [5]. Во оригиналната формулација моделот поддржува повеќе типови јазли и рабови. Бидејќи локалните графови во податочното множество опфатено во оваа дипломска работа содржат еден тип јазол, ентитет, трансформациите зависни од типот на јазолот се сведуваат на заеднички проекции. Релациските трансформации, пак, кои се суштински за HGT, остануваат различни за секој тип раб.

За секој јазол се создаваат проекции за прашање, клуч и вредност. Клучот и

вредноста на изворниот јазол дополнително се трансформираат според типот на релацијата. За работ (u, r, v) и attention head-от j , коефициентот на attention има облик

$$e_{uv}^{r,j} = \frac{(\mathbf{Q}_v^j)^\top \mathbf{R}_{r,\text{att}}^j \mathbf{K}_u^j}{\sqrt{d_j}} \mu_r^j, \quad (14)$$

каде што $\mathbf{R}_{r,\text{att}}^j$ е релатиска трансформација, μ_r^j е научен приоритет на релацијата, а d_j е димензијата на еден head. Вредностите се нормализираат со функцијата *softmax* над сите влезни рабови на целниот јазол:

$$\alpha_{uv}^{r,j} = \frac{\exp(e_{uv}^{r,j})}{\sum_{(u',r',v) \in E} \exp(e_{u'v}^{r',j})}. \quad (15)$$

На овој начин моделот не прави разлика само меѓу типовите релации, туку може да им додели различна важност и на поединечните соседни ентитети. Пораките од сите attention глави се спојуваат, се проектираат и се комбинираат со претходната состојба преку научена резидуална врска и нормализација. Конечните репрезентации повторно се претвораат во логити со заедничкиот повеќеслоен класификатор.

ReaRev. ReaRev е архитектура создадена непосредно за одговарање на прашања над графови на знаење. Нејзината основна идеја е дека инструкциите коишто се влечат од прашањето не треба да останат непроменети во текот на расудувањето. Наместо тоа, моделот наизменично расудува над графот и ги ревидира инструкциите според информациите што ги открил во претходната итерација[6].

Прашањето и текстовите на активните релации се обработуваат со замрзнат MiniLM-енкодер [11]. Наместо единечна векторска репрезентација на целото прашање, се задржуваат репрезентациите на неговите токени. За секоја инструкција k се учи распределба на attention над токениите:

$$\mathbf{i}^{(k)} = \sum_{j=1}^n \beta_j^{(k)} \mathbf{b}_j, \quad (16)$$

каде што $\mathbf{b}_j$ е репрезентацијата на j -тиот токен, а $\beta_j^{(k)}$ е неговата тежина. На овој начин различните инструкции можат да се насочат кон различни делови од прашањето.

ReaRev не користи однапред зададени векторски репрезентации на ентитетите. Почетната состојба на секој јазол се гради од семантичките репрезентации на

релациите што се поврзани со него. Расудувањето започнува од распределба на веројатност над почетните ентитети. Во секој чекор, секоја инструкција создава пораки долж рабовите, а нивната јачина зависи од веројатноста на изворниот јазол:

$$\mathbf{m}_{u,r}^{(k,t)} = p_u^{(t)} \text{ReLU}(\mathbf{W}_r^{(t)} \mathbf{r} \odot \mathbf{i}^{(k)}) . \quad (17)$$

Пораките од сите инструкции се агрегираат во целните јазли, по што се ажурираат нивните состојби и се создава нова распределба на веројатност. Со ова се имитира пребарување во широчина, но правецот и значењето на преносот се контролирани од научените инструкции.

По завршувањето на една итерација, информацијата добиена од графот се користи за ревизија на инструкциите. Новата инструкција зависи од претходната инструкција, состојбата добиена од графот, нивната разлика и нивната елементна интеракција. Научена порта (gate) определува колкав дел од старата инструкција треба да се задржи. Следната итерација повторно започнува од почетните ентитети, но со ревидираните инструкции. По последната итерација, резултатот е распределба на веројатност над сите јазли, а моделот се тренира со KL-дивергенција кон распределбата на точните одговори.

NBFNet. Neural Bellman-Ford Network, односно NBFNet, го разгледува расудувањето како научена варијанта на алгоритмот Bellman-Ford [7]. Наместо една општа репрезентација на секој јазол, моделот учи како секој јазол може да биде достигнат од почетните ентитети во контекст на конкретното прашање. Со тоа, репрезентацијата на јазолот претставува информација за релевантните патеки што водат до него.

Оригиналниот NBFNet е наменет за предвидување врски и е условен од позната релација на барањето. Во оваа примена, релацијата на барањето е заменета со векторска репрезентација на прашањето на природен јазик. По проекцијата се добива векторот $\mathbf{q}$, кој се поставува како почетна состојба за секој почетен ентитет од прашањето:

$$\mathbf{h}_v^{(0)} = \begin{cases} \mathbf{q}, & v \in S, \\ \mathbf{0}, & v \notin S. \end{cases} \quad (18)$$

Кога постојат повеќе почетни ентитети, секој од нив ја добива целосната репрезентација на прашањето. Оваа почетна состојба претставува граничен услов и повторно се вклучува во секој слој, со што сигналот од прашањето не исчезнува при подолгото пренесување.

Репрезентацијата на една релација не е фиксна, туку зависи од прашањето и од слојот:

$$\mathbf{w}_r^{(l)}(\mathbf{q}) = \mathbf{W}_r^{(l)} \mathbf{q} + \mathbf{b}_r^{(l)}. \quad (19)$$

За работ (u, r, v) , пораката се пресметува со елементната DistMult-операција [12]:

$$\mathbf{m}_{u,r,v}^{(l)} = \mathbf{h}_u^{(l)} \odot \mathbf{w}_r^{(l)}(\mathbf{q}). \quad (20)$$

На тој начин иста релација може да има различно значење за различни прашања. Оригиналните и обратните релации имаат посебни параметри, па моделот ја задржува насоката на патеките.

Влезните пораки се комбинираат со PNA-агрегација, која ги користи средната, максималната, минималната вредност и стандардното отстапување, дополнети со скалирање според степенот на јазолот [13]. Агрегираниот резултат се проектира, нормализира и се додава на претходната состојба преку резидуална врска. По последниот слој, состојбата на секој јазол се спојува со репрезентацијата на прашањето и се оценува со повеќеслоен перцептрон:

$$z_v = \text{MLP} [\mathbf{h}_v^{(L)} \parallel \mathbf{q}]. \quad (21)$$

За разлика од ReaRev, кој создава распределба над јазлите во локалниот граф, NBFNet ги оценува одговорите независно со сигмоидна функција. Ова овозможува повеќе јазли истовремено да добијат висока веројатност, што е соодветно за прашањата со повеќе точни одговори.

Табела 1 ги прикажува главните разлики меѓу архитектурите.

3.3 Конструкција на доказен подграф

По пребарувањето, системот располага со рангирано множество ентитети-кандидати, но не и со фактите што објаснуваат како тие се поврзани со прашањето. Затоа, од локалниот граф се издвојува доказен подграф што ги поврзува почетните ентитети со избраните кандидати. Во оваа дипломска работа се споредуваат два пристапа: унија на најкратки патеки и дрво на Штајнер со награди. Двата пристапи работат врз истиот локален граф и создаваат список од оригинални тројки што потоа се доставува до јазичниот модел.

Унија на најкратки патеки. Првиот пристап се заснова врз постапката употребена во GNN-RAG [9]. За секој ентитет-кандидат се бара најкратка патека од секој почетен ентитет присутен во прашањето. Нека $\mathcal{P}(s, c)$ е множеството патеки од почетниот ентитет $s \in S$ до кандидатот $c \in C$. Должината на најкратката патека до кандидатот е

Табела 1: Главни карактеристики на архитектурите за пребарување одговори.

Архитектура	Условување со прашањето	Основен механизам	Релации
GraphSAGE	Семантички тежини на рабовите	Пондерирана агрегација на соседството	Текстуални репрезентации
Advance GraphSAGE	Научени тежини и класификатор условен од прашањето	Резидуална агрегација со нормализација	Текстуални репрезентации
R-GCN	Нема непосредно условување	Релациски трансформации со базна декомпозиција	Категоријални типови
HGT	Нема непосредно условување	Релациски multi-head attention	Категоријални типови
ReaRev	Токенски инструкции	Повторливо расудување и ревизија	Текстуални репрезентации
NBFNet	Репрезентација на целото прашање	Научено пренесување долж патеките	Категоријални типови

$$d(S, c) = \min_{s \in S} \min_{P \in \mathcal{P}(s, c)} |P|. \quad (22)$$

За секој кандидат се задржуваат сите патеки со оваа минимална должина:

$$\mathcal{P}^*(S, c) = \{P \in \mathcal{P}(s, c) \mid s \in S, |P| = d(S, c)\}. \quad (23)$$

Конечниот докажен подграф се добива како унија на рабовите од сите пронајдени најкратки патеки:

$$H_{SP} = \bigcup_{c \in C} \bigcup_{P \in \mathcal{P}^*(S, c)} E(P). \quad (24)$$

Патеките се бараат врз структурно ненасочената верзија на локалниот граф. Ова овозможува поврзување и кога оригиналната насока на некоја релација е спротивна од насоката во која се врши пребарувањето. Сепак, во конечниот докажен подграф секој факт се зачувува во својата оригинална насока и со својата оригинална релација. Тројките што се повторуваат и што припаѓаат на повеќе патеки се прикажуваат само еднаш.

Овој пристап настојува да обезбеди патека како доказ за секој достапен ентитет-кандидат. Неговата предност е тоа што не отфрла кандидат којшто може да се поврзи само затоа што патеката до него е подолга. Од друга страна, пак, патеките за различни кандидати се определуваат независно, па нивната унија

поради тоа може да содржи повеќе посредни ентитети и релации отколку што е потребно за создавање заеднички, компактен контекст.

Дрво на Штајнер со награди. Вториот пристап ја разгледува конструкцијата на доказниот подграф како оптимизациски проблем. Дрвото на Штајнер со награди, односно PCST (*Prize-Collecting Steiner Tree*), избира таква поврзана структура за којашто наградата добиена со собирање на наградите од јазлите е најголема, а трошокот којшто се плаќа за вклучување на дополнителни рабови е најмал [8]. Слична формулација за издвојување важни информации од текстуални графови е применета во G-Retriever [10].

Во овој труд почетните ентитети го определуваат коренот на решението, додека ентитетите-кандидати претставуваат јазли со награда. Оптимизациската цел е

$$T^* = \arg \max_T \left(\sum_{v \in V_T} p(v) - \sum_{e \in E_T} c(e) \right), \quad (25)$$

каде што $p(v)$ е наградата на јазолот v , а $c(e)$ е трошокот на работ e . Јазлите што не се кандидати имаат награда нула, но можат да бидат вклучени како посредни Штајнерови јазли ако се потребни за поврзување на вредните кандидати.

Наградите се определуваат според рангот на кандидатите, без да зависат од конкретната распределба на веројатност што ја создава архитектурата. Ако постојат k валидни и достапни кандидати, кандидатот со ранг i добива награда

$$p(c_i) = k - i + 1. \quad (26)$$

Највисоко рангираниот кандидат добива најголема награда, а последниот добива награда еден. Со ова рангирањето од пребарувачот се задржува, но не се претпоставува дека веројатностите од различните архитектури се еднакво калибрирани. За разлика од унијата на најкратки патеки, кандидатите не се задолжителни терминални јазли. PCST може да отфрли кандидат ако наградата што ја носи е помала од трошокот потребен за негово поврзување.

Кога прашањето има еден валиден почетен ентитет, тој непосредно се користи како корен. Кога има повеќе почетни ентитети, се додава привремен синтетички корен поврзан со нив преку рабови со трошок нула. Почетните ентитети се третираат како задолжителни, а синтетичкиот корен и неговите рабови се отстрануваат по решавањето. Така конечниот доказ може да биде составен од повеќе гранки, при што секоја е поврзана со еден од почетните ентитети.

За решавање на PCST се создава структурно ненасочена верзија на оригиналните тројки. Вештачки додадените обратни рабови не се употребуваат, додека паралелните рабови со различни релации се задржуваат како различни мож-

ности. По оптимизацијата, секој избран раб се пресликува назад во соодветната оригинална насочена тројка.

Во рамки на дипломска работата се разгледуваат две стратегии за определување на трошокот. Кај стратегијата со постојан трошок, секој раб има иста вредност:

$$c(e) = \lambda, \quad (27)$$

каде што $\lambda > 0$ ја контролира казната за зголемување на подграфот. Поголема вредност на λ дава поголема предност на пократки и покомпактни решенија, додека помала вредност овозможува вклучување повеќе кандидати и посредни факти.

Кај семантичката стратегија, трошокот зависи од сличноста меѓу прашањето и релацијата на работ:

$$c(e) = \max(\varepsilon, \lambda(1 - \cos(\mathbf{q}, \mathbf{r}_e))), \quad (28)$$

каде што $\mathbf{q}$ и $\mathbf{r}_e$ се векторските репрезентации на прашањето и релацијата, а ε е мала позитивна вредност. Релациите што се семантички поблиски до прашањето имаат помал трошок и поголема е веројатноста да се вклучат во решението. Параметарот λ повторно ја контролира општата рамнотежа меѓу собраната награда и големината на подграфот.

Независно од избраната стратегија, резултатот е множество оригинални тројки со ист формат како кај унијата на најкратки патеки. На тој начин, јазичниот модел добива еднаков вид влез во двата случаи, а експерименталната споредба го изолира влијанието на начинот на кој е избран доказниот подграф.

3.4 Генерирање на конечниот одговор

По конструкцијата на доказниот подграф, избраните тројки се претвораат во текстуален контекст за јазичниот модел. Секоја тројка се запишува во облик

$$\text{почетен ентитет} \rightarrow \text{релација} \rightarrow \text{краен ентитет}. \quad (29)$$

Со ова се задржуваат ентитетите, релациите и оригиналната насока на фактите, без графот да се претвора во слободна природнојазична форма. Структурираниот запис ја намалува можноста да се внесе дополнително значење што не е присутно во графот, а се појавува при вербализацијата.

Јазичниот модел ги добива оригиналното прашање и тројките од доказниот подграф. Во инструкцијата јасно се наведува дека одговорот треба да се заснова исклучиво врз приложените патеки за расудување. Ако контекстот не содржи доволно информации за одговор, од моделот се бара да врати празно множество. На овој начин генеративната компонента ја има улогата на читач и толкувач на веќе пребараните факти, а не на дополнителен извор на знаење.

Секој одговор мора да биде целосно име на ентитет и да претставува посебен елемент од низата одговори. Повторените одговори се отстрануваат, а редоследот на елементите нема влијание врз споредбата со референтното множество.

Во главните експерименти моделот не создава дополнително образложение. На тој начин излезот е ограничен на ентитетите што се потребни за евалуација, а разликите меѓу јазичните модели не зависат од должината или стилот на генерираното објаснување.

Одговор што не е во очекуваниот формат, неуспешно генерирање или надворешна грешка при повикот на моделот се сметаат за неточен резултат. Таквите примероци не се отстрануваат од евалуацијата, бидејќи способноста на моделот доследно да создаде валиден одговор е дел од успешноста на целосниот систем.

4 Експериментална поставеност

Податочно множество. Експериментите се спроведени врз WebQuestionsSP (WebQSP), стандардно податочно множество за одговарање на прашања над графови на знаење [14]. WebQSP содржи прашања на природен јазик поврзани со Freebase, почетните ентитети и точните одговори.

Во користената верзија, секој примерок, како што беше нагласено, дополнително содржи и локален граф составен од Freebase-тројки релевантни за прашањето. Овој граф го определува множеството јазли што моделот може да ги рангира како можни одговори. Поради тоа, пребарувањето не се извршува врз целосниот Freebase, туку врз однапред издвоениот локален граф за конкретното прашање. Почетните ентитети се дадени во самото податочното множество, па поврзувањето на споменатите ентитети во прашањето со ентитети од графот не е дел од задачата на системот.

Податочното множество е поделено на 2 848 примероци за тренирање, 250 за валидација и 1 639 за тестирање. Во експериментите, валидациското и тест-множеството се обединуваат во едно множество од 1 889 примероци за евалуација, додека параметрите на моделите се оптимизираат само врз примероците за тренирање.

Од главната евалуација се исклучуваат примероците чии локални графови не ги

содржат сите означени точни одговори. Кај таквите примероци не е возможно да се достигне целосно пронаоѓање на референтното множество, независно од способноста на моделот. Нивното вклучување би значело мешање на грешките на пребарувачот со ограничувањата на влезниот граф. Бројот на исклучени примероци се евидентира одделно, а сите архитектури се оценуваат врз истото преостанато множество.

Заедничка конфигурација. За споредбата да биде што е можно порамносправна, сите архитектури користат исти поделби на податоците, иста постапка за подготовка на локалните графови и иста постапка за избор на ентитетикандидати. Архитектурите се разликуваат само во влезните репрезентации што природно ги бараат, начинот на пренос и агрегација на информациите и сопствените архитектурни параметри.

Секој модел се тренира 10 епохи со оптимизаторот Adam, стапка на учење 10^{-3} и без тежинско ослабување. Големината на batch-от е еден граф, со што сите архитектури обработуваат еднаков број примероци при секое ажурирање на параметрите. Тренирањето се извршува на една NVIDIA GeForce RTX 5080 графичка карта. За архитектурите што користат екстерни векторски репрезентации се користи енкодерот text-embedding-3-small од провајдерот OpenAI, додека ReaRev го користи својот фиксиран MiniLM-енкодер.

Секоја архитектура се тренира со три почетни вредности за генераторите на случајни броеви (seeds): 42, 1337 и 2026. Овие вредности влијаат врз почетната иницијализација на параметрите и стохастичките операции во текот на тренирањето. Резултатите од повторените извршувања се прикажуваат преку средна вредност и стандардно отстапување.

По оценувањето на сите јазли, се применува праг на веројатност од 0,7. Ако помалку од 10 јазли го надминуваат прагот, множеството се дополнува со највисоко рангираните јазли до најмалку 10 кандидати. Конечниот број ентитетикандидати е ограничен на 15. Оваа постапка е иста за сите архитектури и овозможува нивните резултати да се споредуваат без различни правила за избор.

Вредностите на заедничката конфигурација за тренирање и пребарување можат да се погледнат во Табела 2

4.1 Метрики за пребарување

Квалитетот на пребарувачот се оценува независно од конструкцијата на доказниот контекст и од јазичниот модел. За секое прашање, нека G_q е множеството точни одговори, а $R_q^{(k)}$ множеството од првите k рангирани ентитетикандидати.

Метриката *погодоци во првите k* , односно Hits@ k покажува дали меѓу првите

Табела 2: Заедничка конфигурација за тренирање и пребарување.

Параметар	Вредност
Број на епохи	10
Оптимизатор	Adam
Стапка на учење	10^{-3}
Тежинско ослабување	0
Големина на batch	1 граф
Почетни seed вредности	42, 1337, 2026
Праг за избор	0,7
Минимален број кандидати	10
Максимален број кандидати	15

k кандидати е присутен барем еден точен одговор:

$$\text{Hits@}k = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}(G_q \cap R_q^{(k)} \neq \emptyset), \quad (30)$$

каде што Q е множеството евалуирани прашања, а $\mathbb{I}$ е функцијата индикатор. Во експериментите се пресметуваат Hits@1 и Hits@10. Оваа група метрики го мери присуството на барем еден точен одговор, но не покажува колку од сите можни точни одговори биле пронајдени.

За оценување на позицијата на точните одговори во ранг-листата се користи *нормализираната намалена кумулативна придобивка*, односно nDCG [15]. Во оваа дипломска работа се користи бинарна релевантност: точниот одговор има релевантност 1, а останатите кандидати имаат релевантност 0. За првите k позиции важи:

$$\text{DCG@}k = \sum_{i=1}^k \frac{\text{rel}_i}{\log_2(i+1)}, \quad (31)$$

$$\text{nDCG@}k = \frac{\text{DCG@}k}{\text{IDCG@}k}, \quad (32)$$

каде што IDCG@ k е вредноста за идеално рангирање во кое сите точни одговори се поставени на највисоките позиции. За разлика од Hits@ k , nDCG ја наградува појавата на точен одговор поблиску до почетокот на листата и го зема предвид присуството на повеќе точни одговори. Во експериментите се пресметува nDCG@10.

Бидејќи едно WebQSP прашање може да има повеќе точни одговори, дополнително се пресметува *покриеноста на точните одговори при пребарувањето*:

$$\text{RetrievalGoldCoverage} = \frac{1}{|Q|} \sum_{q \in Q} \frac{|G_q \cap R_q|}{|G_q|}, \quad (33)$$

каде што R_q е конечното множество избрани ентитети-кандидати. Ова е макропросек: секое прашање има еднаква тежина, независно од бројот на неговите точни одговори.

Целосната покриеност при пребарувањето го мери процентот на прашања за кои се пронајдени сите точни одговори:

$$\text{RetrievalFullGoldCoverage} = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}(G_q \subseteq R_q). \quad (34)$$

Разликата меѓу овие две метрики е значајна. Ако прашањето има три точни одговори, а пребарувачот пронајде два, покриеноста за тој примерок е $2/3$, но примерокот не придонесува кон целосната покриеност.

4.2 Метрики за доказниот контекст

Овие метрики го оценуваат преминот од рангираните ентитети-кандидати кон доказниот подграф што му се доставува на јазичниот модел. Тие се особено важни за PCST, бидејќи оваа постапка може намерно да отфрли дел од кандидатите ако нивното вклучување не ја оправдува потребната цена на поврзување.

Големината на контекстот се опишува преку *просечниот број тројки*, односно *AverageTriples* и *просечниот број различни јазли*, односно *AverageDistinctNodes* во доказниот подграф. Помала вредност означува покомпактен контекст, но сама по себе не значи дека контекстот е поквалитетен. Поради тоа, големината секогаш се разгледува заедно со покриеноста на кандидатите и точните одговори.

Нека $S_q \subseteq R_q$ е множеството пребарани кандидати што се присутни во доказниот подграф. *Покриеноста на кандидатите во доказниот контекст* се пресметува како:

$$\text{ContextCandidateCoverage} = \frac{1}{|Q|} \sum_{q \in Q} \frac{|S_q|}{|R_q|}. \quad (35)$$

Оваа метрика претставува макропросек на процентот задржани кандидати по прашање. Дополнително се пресметува *процентот на намалување на кандидатите*, односно односот меѓу вкупниот број отфрлени кандидати и вкупниот број влезни кандидати низ целото множество:

$$\text{CandidateReduction} = 100 \cdot \frac{\sum_{q \in Q} |R_q \setminus S_q|}{\sum_{q \in Q} |R_q|}. \quad (36)$$

За да се утврди дали доказниот контекст ја задржува информацијата потребна за одговор, нека C_q биде множеството ентитети што навистина се појавуваат како извор или цел во неговите тројки. *Покриеноста на точните одговори во контекстот* е:

$$\text{ContextGoldCoverage} = \frac{1}{|Q|} \sum_{q \in Q} \frac{|G_q \cap C_q|}{|G_q|}, \quad (37)$$

додека *целосната покриеност во контекстот* го претставува процентот на прашања за кои сите точни одговори се видливи во доказниот подграф:

$$\text{ContextFullGoldCoverage} = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}(G_q \subseteq C_q). \quad (38)$$

Споредбата меѓу покриеноста при пребарувањето и покриеноста во контекстот овозможува директно да се измери загубата на релевантни информации при конструкцијата на доказниот подграф. Ако точниот одговор е пронајден, но не се појавува во контекстот, тогаш загубата настанала во оваа фаза, а не во пребарувачот или во јазичниот модел.

Овие вредности овозможуваат да се анализира компромисот меѓу задржувањето на високопозиционирани кандидати и компактната на доказниот подграф.

4.3 Метрики за конечниот одговор

Конечните одговори се оценуваат како множества, па редоследот по кој јазичниот модел ги навел одговорите не влијае врз точноста. Притоа се прави нормализирање на големината на буквите, интерпункцијата, празните места и англиските членови. Неуспешните повици кон јазичниот модел, како што беше претходно наведено, се третираат како неточни одговори.

Главната метрика е *стапката на погодок* :

$$\text{HitRate} = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}(P_q \cap G_q \neq \emptyset). \quad (39)$$

каде што P_q е множеството одговори генерирани од јазичниот модел. Оваа метрика покажува во колкав дел од прашањата е генериран барем еден точен од-

говор.

Се пресметува и *точното совпаѓање*, како:

$$\text{ExactMatch}(q) = \mathbb{I}(P_q = G_q), \quad (40)$$

Притоа лесно може да се забележи дека оваа метрика е строга. Недостигот на еден точен одговор или додавањето еден неточен одговор го прави целиот примерок неточен. Вкупната точност, пак, е процентот на прашања со точно совпаѓање.

За подетална оценка се користат и микропросечни прецизност, одзив и F1-метрика. Нека TP , FP и FN се вкупните броеви точни предвидени, неточни предвидени и испуштени точни одговори низ сите прашања. Тогаш:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad (41)$$

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (42)$$

За подетална анализа на преминот од доказниот контекст кон конечниот одговор, се разгледуваат два исхода и една условна метрика:

- **FullContextCompleteAnswer** — доказниот контекст ги содржи сите точни одговори и јазичниот модел ги вратил сите;
- **FullContextLLMOmission** — доказниот контекст ги содржи сите точни одговори, но јазичниот модел испуштил најмалку еден од нив;
- **LLMOmissionGivenFullContext** — уделот на примероците кај кои јазичниот модел испуштил најмалку еден точен одговор, пресметан само врз примероците чиј доказен контекст ги содржи сите точни одговори.

Првите два исхода се пресметуваат во однос на сите евалуирани прашања и ја покажуваат нивната застапеност во рамките на целосниот систем. Наспроти нив, **LLMOmissionGivenFullContext** е условна метрика чиј именител ги опфаќа само примероците со целосна покриеност на точните одговори во доказниот контекст. На овој начин може да се изолира неуспехот на јазичниот модел од загубата на информации во претходните фази и директно да се оцени колку често моделот не ги искористува сите достапни точни одговори.

Покрај точноста, се следи и *вкупниот број влезни и излезни токени генерирани од јазичниот модел, односно TotalTokens* за едно експериментално извршување.

Влезните токени ги опфаќаат инструкциите, прашањето и доказниот контекст, а излезните токени се однесуваат на генерираниот одговор. Оваа мерка служи како показател за трошокот, но не претставува директна финансиска споредба, бидејќи цените и токенизацијата се разликуваат меѓу моделите.

Со оваа поделба резултатите не се сведуваат само на една крајна точност. Метриките овозможуваат одделно да се утврди дали неуспехот потекнува од пребарувањето, од конструкцијата на доказниот контекст или од недоволното искористување на достапните информации од страна на јазичниот модел. Дополнително, потрошувачката на токени овозможува постигнатата точност да се разгледа и во однос на ресурсите потребни за генерирање на одговорите.

4.4 Прв експеримент: споредба на архитектурите за пребарување

Целта на првиот експеримент е да се утврди која од разгледуваните архитектури најуспешно ги рангира и пронаоѓа точните одговори во локалните графови. Се споредуваат GraphSAGE, Advance GraphSAGE, R-GCN, HGT, ReaRev и NBFNet. За секоја архитектура однапред се избира една фиксна конфигурација, приспособена на нејзините специфични механизми и мемориски барања.

Во оваа фаза не се конструира доказен контекст и не се повикува јазичен модел, со што влијанието на архитектурата за пребарување се оценува изолирано. Главните споредбени показатели се Hits@ k , nDCG, *RetrievalGoldCoverage* и *RetrievalFullGoldCoverage*. Архитектурата со најдобар вкупен однос меѓу рангирањето и покриеноста на точните одговори се избира за наредните два експерименти.

4.5 Втор експеримент: споредба на постапките за конструкција на доказниот контекст

Вториот експеримент го задржува најдобриот пребарувач и го испитува влијанието на постапката со која пронајдените ентитети-кандидати се претвораат во доказен подграф. Со задржување на истиот пребарувач, разликите меѓу резултатите може да се припишат на конструкцијата на контекстот, а не на различно рангирање на кандидатите.

Како основна постапка се користи унијата на најкратките патеки. Таа се споредува со PCST со константна и со семантичка цена на ребрата. За двете варијанти на PCST се испитуваат вредностите $\lambda \in \{0.01, 0.25, 0.5, 1.0\}$. Пониските вредности поставуваат помала казна за вклучување дополнителни ребра, додека повисоките вредности поттикнуваат покомпактен подграф. Сите кон-

фигурации се применуваат врз резултатите од трите извршувања од првиот експеримент.

Во оваа фаза не се генерираат конечни одговори. Споредбата се заснова врз големината на доказниот подграф, *ContextCandidateCoverage*, процентот на намалување на кандидатите, *ContextGoldCoverage* и *ContextFullGoldCoverage*. На тој начин одделно се оценува дали PCST создава покомпактен контекст без значително губење на точните одговори.

4.6 Трет експеримент: оценување на целосниот систем

Во третиот експеримент се оценува целосниот тек од пребарувањето, преку конструкцијата на доказниот контекст, до генерирањето на конечниот одговор. Се користат истите три извршувања на најдобриот пребарувач, а како контекстуални конфигурации се разгледуваат унијата на најкратките патеки и двете варијанти на PCST со $\lambda = 1.0$. Дополнително, за константната и семантичката варијанта на PCST се вклучува $\lambda = 0.01$ како конфигурација со ниска цена, со цел да се провери дали задржувањето поголем дел од подграфот влијае врз конечните одговори и потрошувачката на токени.

Генерирањето се извршува со DeepSeek-V4-Flash и GPT-5.6 Luna. За двата модели се користат истите пронајдени ентитети-кандидати, истите доказни подграфови и истата постапка за оценување. Со тоа експериментот овозможува две поврзани споредби: влијанието на постапката за конструкција на контекстот врз конечниот одговор и влијанието на изборот на јазичниот модел при непроменет претходен тек.

Главен показател е *HitRate*, а дополнително се разгледуваат и *ExactMatch*, *Precision*, *Recall* и F1-метриката. Условените метрики поврзани со целосен и делумен доказан контекст се користат за да се разграничи загубата на релевантна информација од неспособноста на јазичниот модел да ја искористи веќе достапната информација. Се следи и *TotalTokens* за секое извршување, со цел да се оцени односот меѓу точноста и потрошувачката на токени, особено дали покомпактните контексти добиени со PCST овозможуваат споредливи резултати со помала потрошувачка.

5 Резултати и дискусија


Споредба на архитектурите за пребарување. Резултатите од споредбата на шесте архитектури се прикажани во Табела 3 и на Слика 3. Секоја вредност претставува средна вредност и стандардна девијација од трите извршувањата.

На овој начин се земаат предвид и просечниот квалитет на пребарувањето и стабилноста на архитектурата при различна иницијализација.

Табела 3: Резултати од пребарувањето за различните архитектури. Вредностите се прикажани како средна вредност $\pm$ стандардна девијација од три извршувања. Најдобриот резултат за секоја метрика е означен со задебелен текст.

Архитектура	Hits@1	Hits@10	nDCG@10	RetrievalGoldCoverage	RetrievalFullGoldCoverage
GraphSAGE	0.046 $\pm$ 0.015	0.252 $\pm$ 0.034	0.087 $\pm$ 0.018	0.187 $\pm$ 0.039	0.129 $\pm$ 0.031
Advance GraphSAGE	0.225 $\pm$ 0.041	0.801 $\pm$ 0.019	0.451 $\pm$ 0.047	0.744 $\pm$ 0.029	0.644 $\pm$ 0.036
R-GCN	0.121 $\pm$ 0.076	0.447 $\pm$ 0.201	0.219 $\pm$ 0.134	0.393 $\pm$ 0.200	0.314 $\pm$ 0.178
HGT	0.221 $\pm$ 0.004	0.671 $\pm$ 0.016	0.383 $\pm$ 0.009	0.613 $\pm$ 0.014	0.518 $\pm$ 0.017
ReaRev	0.588 $\pm$ 0.103	0.848 $\pm$ 0.084	0.701 $\pm$ 0.101	0.771 $\pm$ 0.088	0.706 $\pm$ 0.087
NBFNet	0.692 $\pm$ 0.015	0.921 $\pm$ 0.005	0.796 $\pm$ 0.007	0.877 $\pm$ 0.005	0.827 $\pm$ 0.006

NBFNet постигнува најдобар резултат кај сите главни метрики. Архитектурата остварува Hits@1 од 0.692 ± 0.015 и Hits@10 од 0.921 ± 0.005 . Високата вредност на nDCG@10 од 0.796 ± 0.007 покажува дека точните одговори не само што се присутни меѓу избраните кандидати, туку најчесто се поставени и блиску до врвот на ранг-листата. Истовремено, *RetrievalGoldCoverage* изнесува 0.877 ± 0.005 , додека *RetrievalFullGoldCoverage* изнесува 0.827 ± 0.006 .



Слика 3: Споредба на главните метрики за пребарување. Столбовите ја прикажуваат средната вредност, а ознаките за отстапување ја прикажуваат стандардната девијација од трите извршувања.

Малите стандардни девијации на NBFNet покажуваат дека неговите резултати се стабилни за сите три извршувања. Ова е особено важно бидејќи кај дел од останатите архитектури високата средна вредност е придружена со значително поголема варијабилност. Во споредба со второрангираната ReaRev, NBFNet постигнува подобрување од 10.4 процентни поени кај Hits@1, 7.3 процентни

поени кај Hits@10 и 9.5 процентни поени кај nDCG@10. Разликата изнесува 10.6 процентни поени кај *RetrievalGoldCoverage* и 12.1 процентни поени кај *RetrievalFullGoldCoverage*.

Ваквиот резултат е во согласност со начинот на кој NBFNet ја формулира задачата. Наместо да создава општа репрезентација за секој јазол, архитектурата го моделира достигнувањето на можните одговори од почетните ентитети преку патеки условени од самото прашање. Оваа формулација непосредно со одветствува на задачата за пребарување одговори во локален граф на знаење. Сепак, експериментот не овозможува придобивката да се припише на само една компонента на NBFNet, бидејќи истовремено се применуваат условените репрезентации на релациите, DistMult-пораките и PNA-агрегацијата.

ReaRev го постигнува вториот најдобар вкупен резултат, со Hits@1 од 0.588 ± 0.103 , nDCG@10 од 0.701 ± 0.101 и *RetrievalFullGoldCoverage* од 0.706 ± 0.087 . Овие резултати ја потврдуваат користа од приспособливото расудување условено од прашањето. Сепак, значително поголемите стандардни девијации покажуваат повисока чувствителност кон случајната иницијализација.

Advance GraphSAGE остварува големо подобрување во однос на основниот GraphSAGE. Неговиот Hits@10 се зголемува од 0.252 ± 0.034 на 0.801 ± 0.019 , а *RetrievalFullGoldCoverage* од 0.129 ± 0.031 на 0.644 ± 0.036 . Ова покажува дека дополнителното моделирање на релациите, обратните ребра, нормализацијата и условувањето на класификаторот со прашањето се корисни за разгледуваниот проблем. Бидејќи овие промени се испитуваат како една заедничка архитектура, од резултатите не може да се одреди поединечниот придонес на секоја компонента.

Иако Advance GraphSAGE не ги постигнува најдобрите резултати, при практичните извршувања се забележува дека неговото тренирање завршува значително побрзо од тренирањето на посложените архитектури. Времето на тренирање не беше систематски мерено и затоа не се прикажува како посебна експериментална метрика. Сепак, едноставноста на архитектурата и релативно високите резултати укажуваат на поволен практичен однос меѓу квалитетот на пребарувањето, сложеноста на моделот и потребното време за тренирање.

HGT постигнува Hits@1 од 0.221 ± 0.004 , што е речиси еднакво на резултатот на Advance GraphSAGE, но разликата станува поголема кај пошироките граници на рангирањето. Неговиот Hits@10 изнесува 0.671 ± 0.016 , а *RetrievalGoldCoverage* изнесува 0.613 ± 0.014 . Архитектурата е стабилна меѓу трите извршувања, но релацискиот multi-headed attention не ја надминува поедноставната Advance GraphSAGE конфигурација. Ова укажува дека поголемата архитектонска сложеност сама по себе не гарантира подобро пребарување.

R-GCN покажува најголема варијабилност меѓу извршувањата. Неговиот про-

сечен Hits@10 изнесува 0.447, но стандардната девијација е 0.201. Слично однесување се забележува кај *RetrievalGoldCoverage*, каде што резултатот е 0.393 ± 0.200 . Едно извршување се приближува до резултатите на HGT, додека останатите две се значително послаби. Следствено, релациски специфичните трансформации имаат потенцијал да бидат корисни, но употребената R-GCN конфигурација не обезбедува стабилно тренирање за овој проблем.

За крај, основниот GraphSAGE постигнува најниски резултати: Hits@1 од 0.046 ± 0.015 , nDCG@10 од 0.087 ± 0.018 и *RetrievalGoldCoverage* од 0.187 ± 0.039 . Ова е очекувано, земајќи ги во предвид ограничувањата на архитектура која првенствено ги агрегира репрезентациите на соседите без експлицитно и целосно моделирање на разновидните типови релации и патеки условени од прашањето.

Резултатите воспоставуваат јасна разлика меѓу општите архитектури за агрегација и архитектурите приспособени за расудување над графови на знаење. Најсилни се ReaRev и NBFNet, кои ја вклучуваат информацијата од прашањето непосредно во процесот на расудување. NBFNet, покрај највисоките средни вредности, покажува и најмала варијабилност меѓу извршувањата. Поради тоа, NBFNet се избира како пребарувач во следните експерименти за конструкција на доказниот контекст и генерирање на конечниот одговор.

Резултати од конструкцијата на доказниот подграф. Во вториот експеримент се споредуваат унијата на најкратки патеки и двете варијанти на PCST: со константна и со семантичка цена на ребрата. За секоја PCST-варијанта се испитуваат вредностите $\lambda \in \{0.01, 0.25, 0.5, 1\}$. Резултатите во Табела 4 се прикажани како средна вредност и стандардна девијација од трите извршувања.

Табела 4: Споредба на постапките за конструкција на доказниот подграф. Вредностите се прикажани како средна вредност $\pm$ стандардна девијација од три извршувања.


Постапка	AverageTriples	AverageDistinctNodes	ContextCandidateCoverage	CandidateReduction [%]	ContextGoldCoverage	ContextFullGoldCoverage
Унија на најкратки патеки	94.47 ± 22.58	32.12 ± 6.60	1.000 ± 0.000	0.00 ± 0.00	0.888 ± 0.006	0.838 ± 0.007
PCST, константна, $\lambda = 0.01$	14.45 ± 0.26	15.46 ± 0.26	1.000 ± 0.000	0.00 ± 0.00	0.881 ± 0.004	0.831 ± 0.005
PCST, константна, $\lambda = 0.25$	14.45 ± 0.26	15.46 ± 0.26	1.000 ± 0.000	0.00 ± 0.00	0.881 ± 0.004	0.831 ± 0.005
PCST, константна, $\lambda = 0.5$	14.30 ± 0.25	15.31 ± 0.25	0.994 ± 0.003	0.61 ± 0.30	0.881 ± 0.004	0.830 ± 0.006
PCST, константна, $\lambda = 1$	13.57 ± 0.26	14.58 ± 0.26	0.949 ± 0.003	5.02 ± 0.33	0.875 ± 0.003	0.816 ± 0.005
PCST, семантичка, $\lambda = 0.01$	13.70 ± 0.28	14.71 ± 0.28	1.000 ± 0.000	0.00 ± 0.00	0.881 ± 0.004	0.831 ± 0.006
PCST, семантичка, $\lambda = 0.25$	13.70 ± 0.28	14.71 ± 0.28	1.000 ± 0.000	0.00 ± 0.00	0.881 ± 0.004	0.831 ± 0.006
PCST, семантичка, $\lambda = 0.5$	13.70 ± 0.28	14.71 ± 0.28	1.000 ± 0.000	0.00 ± 0.00	0.881 ± 0.004	0.831 ± 0.006
PCST, семантичка, $\lambda = 1$	13.50 ± 0.24	14.51 ± 0.24	0.991 ± 0.004	0.82 ± 0.38	0.881 ± 0.004	0.830 ± 0.006

Унијата на најкратки патеки создава најголем доказен контекст, со просечно 94.47 ± 22.58 тројки и 32.12 ± 6.60 различни јазли. Наспроти тоа, сите PCST-конфигурации создаваат подграфови со приближно 13 до 15 тројки и 14 до 16 јазли. Според тоа, PCST го намалува просечниот број тројки за приближно 85%, односно создава речиси седумкратно помал доказен контекст.

Ова намалување не е проследено со соодветно голема загуба на точни одговори. Унијата на најкратки патеки постигнува *ContextGoldCoverage* од 0.888 ± 0.006

и *ContextFullGoldCoverage* од 0.838 ± 0.007 . Кај PCST, овие вредности главно остануваат околу 0.881 и 0.831. Оттука, намалувањето на доказниот контекст за околу 85% предизвикува загуба од помалку од еден процентен поен кај двете метрики за повеќето конфигурации.

Како што покажува Слика 4, промената на λ има ограничено влијание сè до неговата најголема испитана вредност. Кај константната цена, конфигурациите со $\lambda = 0.01$ и $\lambda = 0.25$ даваат идентични агрегирани резултати. Слична стабилност се забележува и кај семантичката цена. Ова покажува дека во тој интервал PCST веќе избира речиси минимална поврзувачка структура, па дополнителното намалување на цената не внесува нови ребра во решението.



Слика 4: Влијание на параметарот λ врз големината на доказниот подграф, намалувањето на кандидатите и покриеноста на точните одговори. Испрекинатата линија го означува резултатот на унијата на најкратки патеки.

Најизразена промена се јавува кај константната цена со $\lambda = 1$. Таа го намалува бројот на кандидати присутни во контекстот за $5.02 \pm 0.33\%$, додека *ContextFullGoldCoverage* се намалува на 0.816 ± 0.005 . Оваа конфигурација создава покомпактен подграф, но понекогаш отстранува ентитети-кандидати потребни за целосно покривање на точниот одговор.

Семантичката варијанта е постабилна при поголема цена. Со $\lambda = 1$ таа создава

најмал просечен подграф, со 13.50 ± 0.24 тројки и 14.51 ± 0.24 јазли, но задржува 0.991 ± 0.004 од кандидатите. Нејзините вредности за *ContextGoldCoverage* и *ContextFullGoldCoverage* остануваат 0.881 ± 0.004 и 0.830 ± 0.006 . Семантичката цена, според тоа, овозможува избор на компактни патеки преку релации што се порелевантни за прашањето, без изразено отстранување на ентитетите-кандидати.

Резултатите покажуваат дека главната предност на PCST е отстранувањето на голем број дополнителни тројки што ги внесува унијата на најкратки патеки. Истовремено, малите разлики меѓу повеќето вредности на λ покажуваат дека PCST брзо достигнува стабилна и компактна поврзувачка структура. За последователната евалуација со јазичниот модел се задржуваат унијата на најкратки патеки, како и константната и семантичката PCST-варијанта со $\lambda = 1$ и $\lambda = 0.01$. Вредноста $\lambda = 1$ претставува построго казнување на дополнителните рабови, додека $\lambda = 0.01$ служи како ниска гранична вредност кај која трошокот за нивно вклучување е речиси занемарлив.


Резултати од целосниот систем. Во последниот експеримент се испитува како различните постапки за конструкција на доказниот подграф влијаат врз квалитетот на конечниот одговор и вкупниот број потрошени токени. За сите конфигурации се користи NBFNet како пребарувач, додека одговорите се генерираат со DeepSeek-V4-Flash и GPT-5.6 Luna. Резултатите се прикажани во Табела 5 и на Слика 5 како средна вредност и стандардна девијација од трите извршувања.

Табела 5: Квалитет на конечните одговори и вкупен број потрошени токени. Највисоката вредност за секоја метрика за квалитет и најмалиот број токени се означени со задебелен текст.

Јазичен модел	Доказан подграф	Hit	Precision	Recall	F1	ExactMatch	TotalTokens [милиони]
DeepSeek-V4-Flash	Најкратки патеки	0.802 ± 0.005	0.860 ± 0.009	0.493 ± 0.007	0.627 ± 0.008	0.580 ± 0.003	3.42 ± 0.77
	PCST, конст., $\lambda = 0.01$	0.598 ± 0.012	0.881 ± 0.006	0.259 ± 0.005	0.400 ± 0.007	0.322 ± 0.002	0.72 ± 0.01
	PCST, конст., $\lambda = 1$	0.594 ± 0.014	0.884 ± 0.007	0.257 ± 0.006	0.398 ± 0.008	0.320 ± 0.002	0.69 ± 0.01
	PCST, сем., $\lambda = 0.01$	0.688 ± 0.007	0.885 ± 0.008	0.342 ± 0.008	0.493 ± 0.010	0.410 ± 0.003	0.69 ± 0.01
	PCST, сем., $\lambda = 1$	0.689 ± 0.006	0.886 ± 0.008	0.341 ± 0.008	0.492 ± 0.010	0.411 ± 0.004	0.69 ± 0.01
GPT-5.6 Luna	Најкратки патеки	0.804 ± 0.015	0.846 ± 0.007	0.481 ± 0.006	0.613 ± 0.006	0.571 ± 0.006	3.07 ± 0.66
	PCST, конст., $\lambda = 0.01$	0.651 ± 0.009	0.847 ± 0.001	0.261 ± 0.004	0.399 ± 0.005	0.341 ± 0.006	0.70 ± 0.01
	PCST, конст., $\lambda = 1$	0.645 ± 0.015	0.849 ± 0.006	0.260 ± 0.004	0.398 ± 0.006	0.331 ± 0.009	0.67 ± 0.01
	PCST, сем., $\lambda = 0.01$	0.723 ± 0.004	0.850 ± 0.008	0.331 ± 0.004	0.476 ± 0.005	0.414 ± 0.003	0.67 ± 0.01
	PCST, сем., $\lambda = 1$	0.728 ± 0.006	0.854 ± 0.007	0.331 ± 0.006	0.477 ± 0.006	0.414 ± 0.005	0.66 ± 0.01

Најдобри резултати се добиваат со унијата на најкратки патеки. DeepSeek-V4-Flash постигнува *Hit* од 0.802 ± 0.005 и F1 од 0.627 ± 0.008 , додека GPT-5.6 Luna постигнува *Hit* од 0.804 ± 0.015 и F1 од 0.613 ± 0.006 . Разликата во *Hit* меѓу моделите е мала. DeepSeek-V4-Flash, сепак, постигнува повисоки вредности за прецизноста, одзивот, F1 и *ExactMatch*, што укажува дека почесто го враќа целосното множество одговори со помалку неточни дополнувања и помалку испуштени одговори.

PCST со константна цена создава најголемо намалување на квалитетот. За $\lambda =$



Слика 5: Квалитет на конечниот одговор и број потрошени токени за различните доказни подграфови. Во приказот на токени, главниот дел од секој столб го претставува влезниот контекст, а горниот шрафиран дел ги претставува излезните токени.

1, *Hit* изнесува 0.594 ± 0.014 со DeepSeek-V4-Flash и 0.645 ± 0.015 со GPT-5.6 Luna. Во однос на унијата на најкратки патеки, тоа претставува намалување од приближно 21 и 16 процентни поени. Намалувањето на λ на 0.01 не носи значително подобрување, што е во согласност со претходниот експеримент, каде што двете конфигурации создаваа речиси исти доказни подграфови.

Семантичката PCST-варијанта постигнува подобар однос меѓу компактоста и квалитетот. За $\lambda = 1$, DeepSeek-V4-Flash постигнува *Hit* од 0.689 ± 0.006 , а GPT-5.6 Luna 0.728 ± 0.006 . Вредностите на F1 се 0.492 ± 0.010 и 0.477 ± 0.006 . Семантичката цена, според тоа, помага да се задржат релациите што се покорисни за одговарање на прашањето, иако создадениот подграф има приближно иста големина како кај константната варијанта.

Разликите меѓу $\lambda = 0.01$ и $\lambda = 1$ кај семантичката варијанта се мали. Ова дополнително покажува дека, во разгледуваниот интервал, изборот меѓу константна и семантичка цена има поголемо влијание од прецизното поставување на λ .


Квалитет и потрошувачка на токени. Унијата на најкратки патеки користи просечно 3.42 ± 0.77 милиони токени со DeepSeek-V4-Flash и 3.07 ± 0.66 милиони со GPT-5.6 Luna. Наспроти тоа, PCST-конфигурациите користат приближно од 0.66 до 0.72 милиони токени. PCST, според тоа, ја намалува потрошувачката на токени за приближно 78–80%.

Најмала потрошувачка е добиена со семантички PCST, $\lambda = 1$, и GPT-5.6 Luna: 0.66 ± 0.01 милиони токени. Истата конфигурација постигнува *Hit* од 0.728 ± 0.006 , односно губи околу 7.6 процентни поени во споредба со најкратките патеки, но користи приближно 4.6 пати помалку токени. Токму затоа, таа претставува најповолен компромис кога намалувањето на должината и цената на

контекстот е поважно од постигнувањето на максималниот квалитет.

Искористување на доказниот контекст. Иако PCST задржува речиси иста покриеност на точните одговори како унијата на најкратки патеки, квалитетот на генерираните одговори е значително помал. Ова покажува дека самото присуство на точниот ентитет во контекстот не е доволно. На јазичниот модел му се потребни и релациските тројки што ја објаснуваат врската меѓу прашањето и одговорот.

Со најкратките патеки, според Слика 6, *FullContextCompleteAnswer* изнесува 0.661 ± 0.004 за DeepSeek-V4-Flash и 0.639 ± 0.003 за GPT-5.6 Luna. Во истите конфигурации, *FullContextLLMOmission* изнесува 0.177 ± 0.003 и 0.198 ± 0.010 .



Слика 6: Исходи од искористувањето на точните одговори присутни во доказниот контекст.

Кај константниот PCST со $\lambda = 1$, *FullContextCompleteAnswer* се намалува на 0.337 ± 0.006 за DeepSeek-V4-Flash и 0.349 ± 0.010 за GPT-5.6 Luna. Истовремено, *FullContextLLMOmission* се зголемува на 0.479 ± 0.007 и 0.468 ± 0.013 . Следствено, може да се заклучи дека во голем дел од прашањата PCST ги задржува точните ентитети, но компактниот контекст не му обезбедува доволно релациски информации на моделот за тие ентитети да биде избрани како одговор.

Семантичкиот PCST ја намалува оваа загуба. За $\lambda = 1$, *FullContextCompleteAnswer* е приближно 0.434 кај двата јазични модели, додека *FullContextLLM-*

Omission е приближно 0.396. Овие резултати се подобри од константната варијанта, но сè уште се значително послаби од унијата на најкратки патеки.

Со ова, резултатите ја покажуваат разликата меѓу покриеноста и употребливоста на доказниот контекст. PCST успешно ги задржува ентитетите-кандидати во многу пократок контекст, но дел од отстранетите тројки содржат информации што му помагаат на јазичниот модел да го препознае одговорот. Унијата на најкратки патеки го постигнува најдобриот конечен квалитет, додека семантичкиот PCST обезбедува поефикасен компромис меѓу квалитетот и потрошувачката на токени.

Загуба на информации низ системот. Резултатите овозможуваат да се проследи движењето на информациите низ трите главни фази: пребарување на ентитети-кандидати, конструкција на доказниот контекст и генерирање на конечниот одговор. Притоа, преминот не претставува строго опаѓачка низа. При конструкцијата на доказниот подграф може да бидат вклучени и точни ентитети што не биле директно избрани како кандидати, доколку тие се појавуваат како посредни јазли на избраните патеки. Поради тоа, *ContextGoldCoverage* во одредени конфигурации може да биде малку повисока од *RetrievalGoldCoverage*.

NBFNet постигнува *RetrievalGoldCoverage* од 0.877 ± 0.005 . Со унијата на најкратки патеки, *ContextGoldCoverage* изнесува 0.888 ± 0.006 , а *ContextFullGoldCoverage* 0.838 ± 0.007 . Кај PCST, покриеноста останува блиска до овие вредности и покрај приближно седумкратното намалување на бројот тројки. Според тоа, најголемата загуба не се појавува при пренесувањето на точните ентитети од пребарувањето во доказниот контекст.

Позначителна загуба се забележува во фазата на генерирање. Со најкратките патеки, одзивот на конечните одговори изнесува 0.493 ± 0.007 за DeepSeek-V4-Flash и 0.481 ± 0.006 за GPT-5.6 Luna, иако доказниот контекст содржи значително голем дел од точните одговори. Дури и кога контекстот ги содржи сите означени одговори, јазичните модели не секогаш ги враќаат сите. Условната стапка *LLMOmissionGivenFullContext* изнесува 0.211 ± 0.002 за DeepSeek-V4-Flash и 0.237 ± 0.010 за GPT-5.6 Luna со најкратките патеки.

Кај PCST разликата е уште поизразена. Семантичката варијанта со $\lambda = 1$ постигнува *ContextFullGoldCoverage* од 0.830 ± 0.006 , но *LLMOmissionGivenFullContext* е приближно 0.477 кај двата јазични модели. Ова покажува дека присуството на точниот ентитет не е доволно ако доказниот подграф не содржи доволно јасна релациска врска меѓу прашањето и одговорот. Отстранетите тројки можеби не влијаат врз покриеноста, но може да содржат корисни посредни факти што му овозможуваат на јазичниот модел правилно да го протолкува контекстот.

Оттука, грешките на целосниот систем не може да се припишат само на пре-

барувачот. Дел од нив настануваат поради изборот на доказниот подграф, а значителен дел во самото генерирање. Ова ја потврдува потребата трите фази да се оценуваат одделно, наместо квалитетот на системот да се претстави само преку една конечна метрика.

Ограничувања Експерименталната анализа е ограничена на WebQSP податочното множество и на локалните графови конструирани за неговите прашања. Поради тоа, заклучоците не мора непосредно да важат за податочни множества со поголеми графови, поинаква структура на релациите или прашања што бараат подолги патеки на расудување.

Архитектурите се оценуваат во заедничка рамка за пребарување одговори. Ова овозможува нивна директна споредба, но некои од нив претставуваат приспособувања на модели што првично биле предложени за други задачи. На пример, HGT се применува врз само еден тип јазли, додека, пак, NBFNet е приспособен од предвидување врски кон одговарање на прашања.

За секоја конфигурација се користат три случајни seeds, а резултатите се прикажуваат преку средна вредност и стандардна девијација. Овој број овозможува основна проценка на стабилноста, но не е доволен за посилни заклучоци преку тестови за статистичка значајност. Дополнително, разгледан е ограничен избор на архитектурни поставки, PCST-параметри и само два јазични модели.

За крај, потрошувачката е прикажана преку бројот на токени, без директна споредба на цената. Бројот на токени не претставува целосно споредлива мерка меѓу различни јазични модели, бидејќи тие може да користат различни токенизатори и да имаат различни цени по единица токени. Поради тоа, оваа мерка првенствено се користи за споредба на доказните стратегии во рамките на истиот модел.

6 Заклучок

Во оваа дипломска работа беше испитан целосен пристап за одговарање на прашања над графови на знаење, составен од пребарување одговори-кандидати, конструкција на доказен подграф и генерирање конечен одговор со јазичен модел. Одделното оценување на овие фази овозможи да се утврди не само која конфигурација постигнува најдобар конечен резултат, туку и каде се губат информациите во текот на системот.

Споредбата на шесте архитектури покажа дека NBFNet е најуспешниот пребарувач за разгледуваната задача. Архитектурата постигна Hits@10 од 0.921 ± 0.005 , nDCG@10 од 0.796 ± 0.007 , *RetrievalGoldCoverage* од 0.877 ± 0.005 и *Retrieval-FullGoldCoverage* од 0.827 ± 0.006 . Овие резултати покажуваат дека условување-

то со прашањето и експлицитното моделирање на релациските патеки се особено соодветни за пребарување над WebQSP. Advance GraphSAGE, иако не ги постигна најдобрите резултати, покажа дека и релативно едноставна архитектура може да обезбеди добар однос меѓу квалитетот и сложеноста.

Начинот на кој пронајдените кандидати се претвораат во доказен контекст, исто така, има значително влијание. Унијата на најкратки патеки создава поголеми доказни подграфови, но задржува повеќе релациски информации и овозможува најдобри конечни одговори. PCST, пак, го намалува просечниот број тројки за приближно 85% и потрошувачката на токени за околу 78–80%, без големо намалување на покриеноста на точните ентитети. Сепак, пократкиот контекст не резултира автоматски со еднакво квалитетни одговори. Од двете PCST-варијанти, семантичката цена постигна подобар компромис меѓу компактноста и зачувувањето на релевантните докази.

Најдобриот целосен резултат беше добиен со NBFNet и унијата на најкратки патеки. GPT-5.6 Luna постигна највисок *Hit* од 0.804 ± 0.015 , додека DeepSeek-V4-Flash постигна речиси еднаква вредност од 0.802 ± 0.005 и повисок F1 од 0.627 ± 0.008 . Разликите покажуваат дека изборот на јазичен модел зависи и од посакуваниот критериум: GPT-5.6 Luna почесто враќа барем еден точен одговор, додека DeepSeek-V4-Flash создава попрецизни и поцелосни множества одговори.

Главното тесно грло во системот се појавува при преминот од доказниот контекст кон конечниот одговор. Покриеноста на точните ентитети останува висока и кај двата пристапи за конструкцијата на доказниот подграфот, но јазичниот модел не успева секогаш да ги искористи достапните информации. Ова е особено изразено кај компактните PCST-подграфови: точниот ентитет често е присутен во контекстот, но моделот сепак не го вклучува во одговорот. Оттука, покрај присуството на точните ентитети, важни се и релациските патеки што јасно ја објаснуваат нивната поврзаност со прашањето.

За крај, резултатите потврдуваат дека успешноста на системот зависи од усогласеноста на сите три фази. За максимален квалитет, најуспешна е комбинацијата од NBFNet и унијата на најкратки патеки. Кога приоритет се пократок контекст и помала потрошувачка на токени, семантичкиот PCST претставува поповолна алтернатива. Со тоа се покажува дека изборот на доказниот подграф не е само прашање на намалување на неговата големина, туку и на зачувување на информациите потребни за правилно расудување над графот.

7 Идни подобрувања

Една од главните идни насоки е развој на хибридна стратегија за конструкција на доказниот подграф. Таа би можела да ја задржи компактната на PCST, но да гарантира дека за најважните ентитети-кандидати ќе останат целосни и разбирливи релациски патеки. Наградите на јазлите и цените на ребрата би можеле да се определуваат според веројатностите на пребарувачот, релевантноста на релациите и нивниот придонес кон квалитетот на конечниот одговор.

Дополнително, пребарувачот и постапката за градење на доказниот подграф би можеле да се оптимизираат заеднички. Наместо доказниот подграф да се гради дури по завршеното пребарување, моделот би можел непосредно да предвидува кои патеки и тројки се најкорисни за јазичниот модел. Кај NBFNet, научените патеки може да се искористат и за создавање објаснувања за изборот на ентитетите-кандидати.

Корисна следна анализа, исто така, би била и одделното испитување на компонентите на Advance GraphSAGE, како и на фиксните архитектурни одлуки кај останатите модели. Со ова би се утврдил поединечниот придонес на обратните ребра, релациските трансформации, attention-от, условувањето со прашањето и адаптивното расудување.

Конечно, експериментите може да се прошират со дополнителни податочни множества, повеќе извршувања и други јазични модели. Тоа би овозможило по-сигурна статистичка анализа и проверка дали заклучоците важат и за поголеми графови, подолги патеки на расудување и прашања со поинаква структура.

Литература

- [1] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [2] Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d’Amato, Gerard de Melo, Claudio Gutiérrez, Sabrina Kirrane, José Emilio Labra Gayo, Roberto Navigli, Sebastian Neumaier, Axel-Cyrille Ngonga Ngomo, Axel Polleres, Sabbir M. Rashid, Anisa Rula, Lukas Schmelzeisen, Juan Sequeda, Steffen Staab, and Antoine Zimmermann. Knowledge graphs. *ACM Computing Surveys*, 54(4):71:1–71:37, 2021. doi: 10.1145/3447772.

- [3] William L. Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems*, volume 30, pages 1024–1034, 2017.
- [4] Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, and Max Welling. Modeling relational data with graph convolutional networks. In *The Semantic Web*, volume 10843 of *Lecture Notes in Computer Science*, pages 593–607. Springer, 2018. doi: 10.1007/978-3-319-93417-4_38.
- [5] Ziniu Hu, Yuxiao Dong, Kuansan Wang, and Yizhou Sun. Heterogeneous graph transformer. In *Proceedings of The Web Conference 2020*, pages 2704–2710. ACM, 2020. doi: 10.1145/3366423.3380027.
- [6] Costas Mavromatis and George Karypis. ReaRev: Adaptive reasoning for question answering over knowledge graphs. In *Findings of the Association for Computational Linguistics: EMNLP 2022*, pages 2447–2458, Abu Dhabi, United Arab Emirates, 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-emnlp.181. URL <https://aclanthology.org/2022.findings-emnlp.181/>.
- [7] Zhaocheng Zhu, Zuobai Zhang, Louis-Pascal A. C. Xhonneux, and Jian Tang. Neural bellman-ford networks: A general graph neural network framework for link prediction. In *Advances in Neural Information Processing Systems*, volume 34, pages 29476–29490, 2021.
- [8] Michel X. Goemans and David P. Williamson. A general approximation technique for constrained forest problems. *SIAM Journal on Computing*, 24(2):296–317, 1995. doi: 10.1137/S0097539793242618.
- [9] Costas Mavromatis and George Karypis. GNN-RAG: Graph neural retrieval for efficient large language model reasoning on knowledge graphs. In *Findings of the Association for Computational Linguistics: ACL 2025*, pages 16682–16699, Vienna, Austria, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.findings-acl.856. URL <https://aclanthology.org/2025.findings-acl.856/>.
- [10] Xiaoxin He, Yijun Tian, Yifei Sun, Nitesh V. Chawla, Thomas Laurent, Yann LeCun, Xavier Bresson, and Bryan Hooi. G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-4224. URL https://proceedings.neurips.cc/paper_files/paper/2024/hash/efaf1c9726648c8ba363a5c927440529-Abstract.html.
- [11] Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, and Ming Zhou. MiniLM: Deep self-attention distillation for task-agnostic compression of pre-

- trained transformers. In *Advances in Neural Information Processing Systems*, volume 33, pages 5776–5788, 2020.
- [12] Bishan Yang, Wen-tau Yih, Xiaodong He, Jianfeng Gao, and Li Deng. Embedding entities and relations for learning and inference in knowledge bases. In *International Conference on Learning Representations*, 2015. URL <https://mlanthology.org/iclr/2015/yang2015iclr-embedding/>.
 - [13] Gabriele Corso, Luca Cavalleri, Dominique Beaini, Pietro Liò, and Petar Veličković. Principal neighbourhood aggregation for graph nets. In *Advances in Neural Information Processing Systems*, volume 33, pages 13260–13271, 2020.
 - [14] Wen-tau Yih, Matthew Richardson, Christopher Meek, Ming-Wei Chang, and Jina Suh. The value of semantic parse labeling for knowledge base question answering. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 201–206, Berlin, Germany, 2016. Association for Computational Linguistics. doi: 10.18653/v1/P16-2033.
 - [15] Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of ir techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002. doi: 10.1145/582415.582418.